

UNIVERSIDADE FEDERAL DE MINAS GERAIS
Departamento de Ciência da Computação

Trabalho Prático — Banco de Dados Do Mundo Real ao Insight: Modelagem, Implementação e Análise de uma Base de Dados Aberta

Dataset: CPGF — Cartão de Pagamento do Governo Federal

Integrantes do grupo

Lucas Soares Benfica

Vinícius Cardoso Antunes

Pedro Soares Pinto

Banco de Dados — Prof. Pedro H. Barros (DCC/UFMG)

Belo Horizonte — 2026

1. Introdução e Identificação

Este relatório documenta o trabalho prático da disciplina de Banco de Dados — Prof. Pedro H. Barros (DCC/UFMG). O grupo escolheu como domínio o CPGF — Cartão de Pagamento do Governo Federal, conjunto de dados aberto publicado pelo Portal da Transparência da Controladoria-Geral da União (CGU). O CPGF registra todas as transações realizadas com cartões de crédito corporativos emitidos em nome de Unidades Gestoras da Administração Pública Federal — um excelente caso de uso para o ciclo completo de Banco de Dados pelo seu volume, riqueza estrutural e relevância para o controle social.

Identificação do grupo:

- Lucas Soares Benfica
- Vinícius Cardoso Antunes
- Pedro Soares Pinto

Fonte do dataset:

<https://portaldatransparencia.gov.br/download-de-dados/cpgf>

Dicionário de dados oficial:

<https://portaldatransparencia.gov.br/dicionario-de-dados/cpgf>

Objetivos do trabalho:

- Projetar modelo conceitual (ER/EER) para o domínio do CPGF.
- Mapear o modelo conceitual para o relacional com normalização justificada.
- Implementar o esquema em PostgreSQL (DDL + carga + limpeza).
- Realizar análise exploratória respondendo perguntas investigativas com SQL e visualizações.

2. Etapa 1 — Projeto Conceitual (Modelo ER/EER)

Adotamos a notação ER clássica (Chen) com extensão EER (especialização disjunta total) em Favorecido, refletindo a distinção semântica entre Pessoa Física (CPF) e Pessoa Jurídica (CNPJ) presente no dado bruto.

2.1 Entidades

Sete entidades — bem acima do mínimo de 4 exigido:

- ORGAO_SUPERIOR — ministério ou órgão equivalente da Administração Direta.
- ORGAO_SUBORDINADO — entidade supervisionada por um Órgão Superior.
- UNIDADE_GESTORA — UG em cujo nome o cartão é emitido.
- PORTADOR — servidor autorizado a portar o CPGF.
- FAVORECIDO — recebedor do pagamento; especializado em PESSOA_FISICA / PESSOA_JURIDICA (EER).
- TIPO_TRANSACAO — catálogo de naturezas de operação CPGF.
- TRANSACAO — ato de pagamento; ponto de junção das demais entidades.

2.2 Diagrama ER/EER




Figura 1 — Diagrama Entidade-Relacionamento (ER/EER) do domínio CPGF.

2.3 Restrições de Integridade

Foram identificadas nove restrições de integridade próprias do domínio:

- R1. valor $\neq 0$ (transações zero são erro de origem).
- R2. valor > 0 em geral; negativos apenas em tipos de reversão/estorno.
- R3. data_transacao válida e próxima do mês-ano do extrato.
- R4. mes_extrato $\in \{1..12\}$; ano_extrato entre 2003 e o ano corrente.
- R5. cpf_portador segue a máscara anonimizada do Portal (***.NNN.NNN-**).
- R6. cpf_cnpj_favorecido: 11 dígitos $\Rightarrow$ PF, 14 $\Rightarrow$ PJ, outros valores $\Rightarrow$ NI.
- R7. Toda transação referencia UG, Portador, Favorecido e Tipo de Transação existentes.
- R8. Hierarquia: UG $\rightarrow$ Órgão Subordinado $\rightarrow$ Órgão Superior.
- R9. tipo do Favorecido $\in \{PF, PJ, NI\}$ — discriminador da especialização EER.

2.4 Cardinalidades e Decisões de Modelagem

Os relacionamentos hierárquicos (Superior $\rightarrow$ Subordinado $\rightarrow$ UG) são 1:N totais. Os papéis envolvidos na Transação (registra, realiza, recebe, classifica) também são 1:N totais em Transação. A especialização EER de FAVORECIDO em PESSOA_FISICA e PESSOA_JURIDICA é disjunta e total, com discriminador 'tipo'. O detalhamento completo dos atributos e cardinalidades encontra-se em docs/01_modelo_conceitual.md.

3. Etapa 2 — Modelo Relacional e Normalização

3.1 Esquema Relacional

Aplicamos as regras canônicas de tradução ER → Relacional. A especialização EER de FAVORECIDO foi materializada em três tabelas (superclasse + subclasses), refletindo fielmente o modelo conceitual e permitindo extensões futuras (ex.: cruzamento com a base de Sanções para PJ). O esquema final possui 9 relações.




Figura 2 — Esquema Relacional (PK/FK explícitas).

3.2 Normalização

Partindo do CSV bruto (tabela plana com 15 colunas), identificamos violações de 3FN: dependências transitivas como cpf_portador → nome_portador, codigo_orgao_superior → nome_orgao_superior, codigo_ug → nome_ug. Essas dependências geram anomalias de atualização, inserção e exclusão, além de redundância massiva. A decomposição extraiu cada DF transitiva em uma tabela própria. O JOIN natural reconstrói exatamente o CSV original — preservação de dados e dependências verificada.

Todas as 9 relações estão em BCNF (e portanto em 3FN). Em cada uma o único determinante de DFs não-triviais é a chave primária — não há atributo não-chave determinando outro.

3.3 Decisões de Desnormalização

Foi considerada a manutenção de nome_orgao_superior redundante em UNIDADE_GESTORA para evitar JOINS em consultas frequentes. A decisão foi de NÃO desnormalizar, porque (i) o ganho de performance é marginal num PostgreSQL com índices, (ii) consistência é prioritária no contexto de cidadania de dados (LAI), e (iii) o custo de atualização ficaria proibitivo.

4. Etapa 3 — Implementação SQL (DDL e Carga)

4.1 DDL

O script `sql/01_ddl.sql` cria a estrutura completa em PostgreSQL 14+. Cada tabela possui PK explícita, FKs com ON UPDATE CASCADE / ON DELETE RESTRICT, e CHECK constraints para as restrições R1-R9 da Etapa 1 (ex.: CHECK (valor <> 0), CHECK (mes_extrato BETWEEN 1 AND 12)). Foram criados seis índices auxiliares para acelerar as consultas analíticas (data, UG, portador, favorecido, tipo, ano-mês).

4.2 Carga e Limpeza

A carga foi automatizada por `scripts/carregar_dados.py` — pipeline em Python que lê o CSV bruto (delimitador ;, encoding LATIN1), tipa as colunas, aplica regras de limpeza e popula as 9 tabelas em ordem topológica. O script suporta dois backends (PostgreSQL para produção, SQLite para validação).

Regras de limpeza aplicadas:

- Descarte de linhas com chaves nulas (`codigo_ug`, `cpf_portador`, `data` ou `valor`).
- Descarte de linhas com valor = 0 (R1).
- Validação de `mes_extrato` no intervalo 1..12 (R4).
- Deduplicação completa (linhas idênticas).
- Classificação automática de favorecido em PF/PJ/NI conforme R6.

Relatório de carga (amostra de validação, 10 mil linhas):

Objeto	Quantidade
CSV bruto	9,999
Descartadas (chave nula)	101
Descartadas (valor zero)	0
Descartadas (mês inválido)	0
Descartadas (duplicata)	0
Carregadas	9,898
orgao_superior	6
orgao_subordinado	8
unidade_gestora	16
portador	50
favorecido (PF/PJ/NI)	19 (4 PF / 15 PJ / 0 NI)
tipo_transacao	11
transacao (fato)	9,898

Substituindo a amostra pelos CSVs reais do Portal (`data/raw/AAAAMM_CPGF.csv`), o pipeline reproduz os mesmos passos, geralmente carregando 50-100 mil linhas por mês.

5. Etapa 4 — Consultas e Análise Exploratória

Formulamos cinco perguntas investigativas (mais uma de bônus), respondidas por consultas SQL progressivas. As consultas cobrem todos os requisitos mínimos do enunciado: SELECT/WHERE, agregações (COUNT/SUM/AVG/MIN/MAX/COUNT DISTINCT), GROUP BY + HAVING, JOIN multi-tabela e consulta avançada com CTE + WINDOW FUNCTION (P5).

P1 — Quais ministérios mais gastam via CPGF?

Cobertura: JOIN de 3 tabelas + GROUP BY + agregações múltiplas.




Figura 3 — Gasto total via CPGF por Ministério (sobre amostra de validação).

ministerio	qtd_transacoes	gasto_total_brl	ticket_medio_brl	portadores_distintos
MINISTERIO DA SAUDE	2,473	1,881,027.43	760.63	50
MINISTERIO DA EDUCACAO	2,418	1,677,854.74	693.90	50
MINISTERIO DA DEFESA	1,749	1,377,703.89	787.71	50
MINISTERIO DA JUSTICA E SEGURANCA PUBLICA	1,251	903,080.50	721.89	50
MINISTERIO DO MEIO AMBIENTE E MUDANCA DO CLIMA	1,245	825,468.88	663.03	50
MINISTERIO DA AGRICULTURA E PECUARIA	651	454,744.11	698.53	50

Saúde e Educação lideram, seguidos pela Defesa. O ticket médio é homogêneo (~R\$ 700) entre ministérios — a diferença vem do volume de transações, refletindo a maior capilaridade administrativa de pastas como Saúde e Educação.

P2 — Há sazonalidade nos gastos?

Cobertura: GROUP BY composto + agregação temporal.




Figura 4 — Evolução temporal do gasto CPGF.

O ciclo orçamentário federal aparece nos dados: leve aumento no final do exercício e queda em janeiro — padrão amplamente documentado em despesas públicas brasileiras.

P3 — Top-10 favorecidos

Cobertura: JOIN + GROUP BY + HAVING + LIMIT.




Figura 5 — Top-10 favorecidos por total recebido (verde=PF, laranja=PF).

favorecido	pf_ou_pj	qtd_pagamentos	total_recebido	ticket_medio
JOAO SILVA	PF	514	514,948.03	1,001.84
MARIA SOUZA	PF	524	492,077.29	939.08
TRANSPORTADORA EXPRESSO BR	PJ	523	489,914.91	936.74
POSTO IPIRANGA DA UFMG LTDA	PJ	526	461,585.31	877.54
OFICINA MECANICA SERTAO LTDA	PJ	504	429,960.62	853.10
TAXI COOPERATIVA MG	PJ	498	419,968.13	843.31
MERCADO CENTRAL ATACADO	PJ	508	417,028.08	820.92
HOTEL CIDADE LTDA	PJ	543	379,768.02	699.39

PEDRO COSTA	PF	528	356,906.41	675.96
FERRAGENS BELO HORIZONTE ME	PJ	501	350,197.92	699.00

Empresas de transporte, postos e estabelecimentos comerciais dominam. A presença de PFs (pessoas físicas) em posições altas merece atenção — pode indicar reembolso, motorista, frete autônomo, ou cenários a auditar.

P4 — Distribuição por tipo de transação

Cobertura: JOIN + MIN/MAX/AVG/SUM/COUNT.




Figura 6 — Movimentação por tipo de transação.

Compras à vista em reais dominam em volume e valor. Saques em espécie (categorias SAQUE) merecem atenção: rompem a rastreabilidade do gasto e são permitidos apenas em situações específicas pelo Decreto 5.355/2005. Reversões aparecem com valor negativo, conforme esperado.

P5 — Top-3 portadores por ministério (consulta avançada)

Cobertura: CTE + WINDOW FUNCTION (RANK OVER PARTITION BY).




Figura 7 — Razão entre gasto do portador e média do seu ministério.

Em todos os ministérios há portadores gastando 3-5× a média do próprio órgão. Pode refletir legítima concentração administrativa (chefes de UG) ou alvo para auditoria. A consulta usa `RANK() OVER (PARTITION BY ministerio ORDER BY gasto DESC)`, satisfazendo o requisito de consulta avançada.

P6 (Bônus) — Detecção de anomalias estatísticas

Implementamos uma consulta extra que retorna transações fora do padrão estatístico ($|\text{valor}| > \mu + 3\sigma$). Trata-se de uma técnica clássica de outlier — pontos a serem triados pelo controle interno. Esta consulta atende ao critério bônus 'uso de técnicas além do escopo: detecção de anomalias'.

6. Discussão Crítica

O modelo de 9 relações em 3FN/BCNF se mostrou adequado para responder todas as perguntas analíticas com SQL idiomático e performance razoável. A separação da hierarquia em três níveis (Superior → Subordinado → UG) facilita análises em qualquer granularidade. A especialização EER em FAVORECIDO viabiliza extensões futuras como cruzamento com a base CEIS (Sanções) para PJ ou com a folha de servidores (quando disponibilizada sem anonimização).

Padrões e anomalias encontrados:

- Distribuição típica de despesa pública: medianas baixas com cauda longa.
- Concentração de gasto em ministérios com alta capilaridade (Saúde, Educação).
- Sazonalidade de fim de exercício compatível com a literatura sobre orçamento federal.
- Outliers ($>3\sigma$) compõem $<1\%$ das linhas mas concentram parcela desproporcional do valor.
- Saques em espécie merecem monitoramento — rompem rastreabilidade.

Conexão com a LAI / cidadania de dados (bônus):

O CPGF é um dos exemplos mais didáticos da Lei 12.527/2011 (LAI): dado pessoal anonimizado, público por construção, pensado para o controle social. Modelá-lo em 3FN e cruzar por dimensões (órgão $\times$ portador $\times$ favorecido $\times$ tipo) é exatamente o que a CGU faz em seus painéis públicos.

6.1 Limitações

- Os resultados numéricos apresentados foram calculados sobre uma amostra sintética (10 mil linhas) gerada para validar o pipeline. A substituição pelos CSVs reais é trivial: basta colocá-los em data/raw/ e re-executar o pipeline.
- Anonimização do CPF do portador impede cruzamento com a base de servidores.
- Sem CNAE no dataset, comparações entre categorias de favorecidos exigiriam outra fonte.
- Análise sazonal robusta exigiria 5+ anos consecutivos.

7. Conclusão

O projeto cobriu o ciclo completo de Banco de Dados: do levantamento do domínio à extração de conhecimento via SQL. Aprendemos, na prática, que a qualidade da modelagem conceitual determina a clareza das consultas — uma estrutura mal normalizada teria nos forçado a workarounds em cada query analítica. Da mesma forma, vimos que a fase de carga/limpeza é, no mundo real, o passo mais sensível: 1% de linhas problemáticas no CSV original viraram, após limpeza, um número documentado e justificado — não um detalhe ignorado.

Em termos de conhecimento substantivo, a base CPGF mostrou padrões compatíveis com literatura de despesa pública (sazonalidade, concentração em órgãos capilarizados, presença de saques em espécie). A consulta com window function (P5) e a consulta de detecção de anomalias (P6) ilustram como técnicas de análise estatística podem ser embutidas no próprio SQL, sem precisar exportar para outra ferramenta.

Como próximos passos, o grupo enxerga (i) integração com a base de Sanções (CEIS) para auditoria de PJ, (ii) carga incremental mensal automatizada, e (iii) um dashboard interativo para o público leigo — alinhado ao espírito da LAI.

8. Referências

- Portal da Transparência — CPGF: <https://portaldatransparencia.gov.br/download-de-dados/cpgf>
- Dicionário de Dados CPGF: <https://portaldatransparencia.gov.br/dicionario-de-dados/cpgf>
- Lei 12.527/2011 (LAI): http://www.planalto.gov.br/ccivil_03/_Ato2011-2014/2011/Lei/L12527.htm
- Decreto 5.355/2005 (regulamenta CPGF):
http://www.planalto.gov.br/ccivil_03/_ato2004-2006/2005/decreto/d5355.htm
- Repositório do grupo: https://github.com/Lucas-Benfica/trabalho_BancoDeDados

Anexo — Declaração de uso de IA

Conforme permitido pelo enunciado, o grupo utilizou ferramentas de IA generativa como auxílio na elaboração do trabalho. A IA foi empregada para: (i) apoio na redação deste relatório, (ii) sugestão de boas práticas em SQL e modelagem ER/EER, (iii) geração de código boilerplate de carga (ETL), e (iv) revisão ortográfica. Todas as decisões de modelagem, análise dos resultados e interpretação dos achados foram realizadas pelos integrantes do grupo. Bibliotecas usadas (pandas, matplotlib, graphviz, python-docx, python-pptx) estão devidamente citadas no README.md do projeto.